

Résumé :


$$y = f(x)$$

label (pointing to y) image (pointing to x)

$$l = \hat{y} - y$$

solution (pointing to $\hat{y}$) label calculé (pointing to y)


$$1 \text{ layer} = x \rightarrow [Wx + b] \rightarrow [\text{ReLU}] \rightarrow y$$



On veut optimiser W et b pour avoir $l = 0$
→ descente stochastique de gradient
→ adapter le pas (L_R)

Hyperparamètres (= paramètres qu'on set au début)

- Nb Layers
- Choix de l'architecture
- Learning Rate
- Optimiseur (DSG)



$$\text{Nb paramètres} = F_{out} \times S_1 \times S_2 \times F_{in}$$

$$\text{Nb multiplications} = H \times W \times F_{in} \times F_{out} \times S_1 \times S_2$$

$$\text{Nb additions} = \text{Nb-multiplication} - 1$$

Reduction de resolution : $\text{stride} > 1$

Élagage (= Pruning)

- **Critère** = Rand? Min?

- **Où?** = Amond?, Avel?

- **Quand?** = Pdt le train? Après le train?

→ **Non structuré** : on prend la $\left\{ \begin{array}{l} \sum \text{Grad} \\ \sum \text{ABS} \end{array} \right.$ de tous les **param** de tout les layers et on suppr. les plus petits

⊕ Perf

⊖ Pas opti car pas implémenté

→ **structuré** : suppr. des filtres directement

⊕ latence

⊖ diff à coder


→ **Local pruning** : on enlève X% parcoure parall

→ **global pruning** : on enlève parcoure différemment

Quantification


Objectif: réduire la taille (bits) des params et des activations

- gain de place mémoire
- BP entre mémoire > cache > ALU
- réduire la conso (moins cher de manipuler des uint8 que des uint32)
- réduire le Temps d'exécution



$$x_q = \begin{cases} -\beta & \text{si } x < -\alpha \\ \frac{Q}{W} x & \text{si } x \in [-\alpha; +\alpha] \\ +\beta & \text{si } x > +\alpha \end{cases}$$

$$x = \frac{W}{Q} x_q$$



Factorisation

Objectif : factoriser les matrices pour
gagner en Nb params

Exemple :
$$\begin{bmatrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{bmatrix} = \begin{bmatrix} 1 \\ 2 \\ 1 \end{bmatrix} \times \begin{bmatrix} -1 & 0 & 1 \end{bmatrix}$$

Grouped Convolution :

On groupe 2 convolutions pour r qu'elles
traitent $\frac{1}{2}$ Features maps en entrée

$\Rightarrow$ Nb mult $\div 2$

